실습 2) Logistic Regression

July 4, 2022

- **default.csv 데이터**: 어느 신용카드 회사의 고객 10,000명에 대한 다음 4개 변수의 정보를 기록
 - default : 해당 고객이 자신의 debt에 대한 default 여부를 나타냄. Yes는 defaulted, No는 not defaulted 를 의미함.
 - student : 해당 고객이 학생인지 여부를 나타냄 Yes 는 학생임 No 는 학생이 아님.
 - balance : 직전 달에 카드사용액을 납부한 이후의 고객의 balance (현 시점까지 빌린 금액).
 - income : 해당 고객의 소득

```
[1]: import pandas as pd
import numpy as np
creditcard = pd.read_csv( 'default.csv' )
creditcard.head()
```

```
[1]:
      default student
                           balance
                                         income
          Yes
                  Yes 1486.998122 17854.39703
    1
          Yes
                  Yes 2205.799521 14271.49225
    2
          Yes
                  Yes 1774.694223 20359.50609
    3
          Yes
                  No 1889.599190 48956.17159
                  Yes 1899.390626 20655.20000
          Yes
```

```
[2]: creditcard['default']= creditcard['default'].map( {'Yes' : 1, 'No' : 0 } )
    creditcard['student']= creditcard['student'].map( {'Yes' : 1, 'No' : 0 } )
    creditcard.head()
```

```
[2]: default student balance income
0 1 1 1486.998122 17854.39703
1 1 1 2205.799521 14271.49225
2 1 1 1774.694223 20359.50609
3 1 0 1889.599190 48956.17159
4 1 1 1899.390626 20655.20000
```

```
[3]: creditcard.info()
```

```
1 student 809 non-null int64
2 balance 809 non-null float64
3 income 809 non-null float64
dtypes: float64(2), int64(2)
```

dtypes: float64(2), int64 memory usage: 25.4 KB

```
[4]: creditcard['default'].value_counts()
```

[4]: 0 476 1 333

Name: default, dtype: int64

• sklearn.preprocession 모듈 : StandardScaler

- 개별 특성 변수를 평균이 0이고 표준편차가 1인 값으로 변환.
- StandardScaler 객체를 생성한 뒤, fit(X) 메서드와 transform(X) 메서드에 변환 대상 특성 데이터 세트를 입력하여 차례로 호출.
- 스케일 변환된 데이터 세트가 ndarray로 반환됨.

• sklearn.linear_model 모듈: LogisticRegression (로지스틱회귀모형)

- 로지스틱회귀모형의 훈련 : sklearn.linear_model 모듈의 LogisticRegression 클래스
 - * sklearn.linear_model.LogisticRegression(penalty='l2', C=1.0, fit_intercept=True, solver='liblinear', max_iter=100)
 - * 입력 파라미터
 - · solver : 최적화에 사용할 알고리즘 결정('newton-cg', 'lbfgs', 'liblinear', 'sag', 'saga')
 - · max_iter :에포크. 한번에 훈련자료 하나씩 뽑아서 가중치 업데이트, 전체 훈련 자료 몇 회 반복할지 결정.
 - · penalty : '11','12' 또는 'none'. '12'가 디폴트임. 각 특성변수 별 가중치가 커지지 못하게 함으로써 과적합을 방지.
 - · C: 1.0이 디폴트. 작은 값일수록 과적합 방지
 - * 메서드
 - · fit(X_train,y_train) 메서드로 모델을 학습.
 - · predict(X_test) 메서드로 새로운 입력데이터에 학습된 모델을 적용한 예측. 클래스 레이블을 반환.
 - · predict_proba(X_test) 메서드는 각 클래스에 속할 확률을 반환.
 - * 속성
 - · coef_: 가중치(기울기계수) 추정치
 - · intercetp_: 편향(절편) 추정치

```
[6]: from sklearn.linear_model import LogisticRegression
     lr_clf = LogisticRegression( penalty='none' )
     lr_clf.fit(X_train, y_train)
     lr_clf.coef_
[6]: array([[-0.38319425, 4.01243062, -0.28954033]])
[7]: coeff = pd.Series( data= np.round( lr_clf.coef_[0], decimals=4),
                       index=[ 'student', 'balance', 'income' ] )
     coeff
[7]: student
              -0.3832
    balance
               4.0124
     income
              -0.2895
     dtype: float64
[8]: y_pred= lr_clf.predict(X_test)
     y_pred[:10]
[8]: array([0, 1, 1, 0, 1, 0, 0, 0, 1, 0], dtype=int64)
[9]: y_pred_proba = lr_clf.predict_proba(X_test)
     y_pred_proba[:10]
[9]: array([[9.98414217e-01, 1.58578314e-03],
            [5.56087590e-03, 9.94439124e-01],
            [4.47809851e-03, 9.95521901e-01],
            [9.03839316e-01, 9.61606843e-02],
            [2.51949981e-01, 7.48050019e-01],
            [8.25459118e-01, 1.74540882e-01],
            [8.95160911e-01, 1.04839089e-01],
            [9.99858686e-01, 1.41314430e-04],
            [2.63891611e-02, 9.73610839e-01],
            [9.98550925e-01, 1.44907466e-03]])
       • sklearn.metric 모듈의 분류 평가를 위한 지표 API
           - 입력파라미터
               * y_true : 실제 범주값 배열
               * y_pred : 예측 범주값 배열
               * y_pred_proba1 : 관심범주(Y=1)의 예측확률값 배열
           - accuracy_score (y_true, y_pred): 정확도
           - confusion_matrix ( y_true, y_pred ) : 교차(혼동) 행렬
           - precision_score (y_true, y_pred): 정밀도
           - recall_score ( y_true, y_pred ): 재현율
           - f1_score ( y_true, y_pred ) : 정밀도와 재현율의 조화평균
           - precision_recall_curve (y_true, y_pred_proba_1): 가능한 모든 임계값에 대해 정밀도와
             재현율의 값을 정렬된 리스트로 반환
```


```
- roc_curve ( y_true, y_pred_proba_1 ) : 가능한 모든 임계값에 대한 FPR과 TPR을 정렬된
리스트로 반환
```

```
- roc_auc_score (y_true, y_pred_proba_1): ROC 커브에서의 곡선 아래 면적(AUC) 반환
```

```
[10]: from sklearn.metrics import accuracy_score, confusion_matrix, precision_score,
       →recall_score, f1_score
      accuracy_score ( y_test, y_pred )
[10]: 0.8847736625514403
[11]: confusion_matrix( y_test, y_pred )
[11]: array([[136, 13],
             [ 15, 79]], dtype=int64)
[12]: precision_score ( y_test, y_pred )
[12]: 0.8586956521739131
[13]: recall_score( y_test, y_pred )
[13]: 0.8404255319148937
[14]: f1_score( y_test, y_pred )
[14]: 0.849462365591398
[15]: from sklearn.metrics import precision_recall_curve
      y_pred_proba1 = y_pred_proba[:,1]
      precisions, recalls, thres = precision_recall_curve( y_test, y_pred_proba1 )
      thres_n = thres.shape[0]
      np.c_[ precisions[ : thres_n ], recalls[ : thres_n ], thres ] [:10]
[15]: array([[0.53409091, 1.
                                    , 0.00871071],
             [0.53142857, 0.9893617, 0.00877631],
             [0.53448276, 0.9893617, 0.00995061],
             [0.53757225, 0.9893617, 0.0105086],
             [0.54069767, 0.9893617, 0.01066104],
             [0.54385965, 0.9893617, 0.01124646],
             [0.54705882, 0.9893617, 0.01231105],
             [0.55029586, 0.9893617, 0.01372781],
             [0.55357143, 0.9893617, 0.01389965],
             [0.55688623, 0.9893617, 0.01578174]])
[16]: import matplotlib.pyplot as plt
      plt.figure(figsize=(8,4))
      plt.plot( thres, precisions[ 0:thres_n ], linestyle='--', label='precision')
```

```
plt.plot( thres, recalls[ 0:thres_n ], label='recall')
plt.xlabel('threshold value')
plt.ylabel('precision and recall values')
plt.legend()
```

[16]: <matplotlib.legend.Legend at 0x374fcb4df0>




[17]: <matplotlib.legend.Legend at 0x374fd90e20>

```
0.9 - --- precision --- precis
```

```
[18]: |y_pred_new = (lr_clf.predict_proba(X_test)[:,1]>=0.6).astype(int)
     y_pred_new
[18]: array([0, 1, 1, 0, 1, 0, 0, 0, 1, 0, 0, 0, 1, 1, 0, 0, 1, 1, 0, 1, 0, 0,
            1, 0, 0, 0, 0, 0, 1, 0, 1, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1,
            0, 0, 0, 0, 1, 1, 0, 1, 0, 0, 1, 1, 0, 0, 0, 0, 0, 1, 1, 0, 0, 0,
            0, 0, 1, 1, 1, 1, 0, 0, 0, 1, 0, 0, 1, 1, 0, 1, 0, 1, 0, 1, 0,
            0, 1, 0, 1, 0, 1, 1, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0,
            0, 0, 0, 0, 0, 0, 0, 1, 1, 0, 0, 0, 1, 0, 0, 1, 0, 0, 1, 1,
            0, 1, 1, 1, 1, 0, 0, 0, 0, 1, 1, 0, 1, 0, 0, 0, 0, 1, 0, 0,
            0, 1, 0, 0, 1, 1, 0, 1, 1, 1, 0, 1, 1, 0, 1, 0, 0, 0, 1, 0, 0, 1,
            0, 0, 1, 1, 0, 1, 0, 0, 0, 0, 1, 1, 1, 0, 0, 1, 0, 1, 0, 1, 0, 0,
            0, 1, 0, 1, 1, 0, 1, 1, 0, 0, 1, 0, 0, 1, 0, 1, 0, 1, 0, 0, 1, 0, 0,
            0])
[19]: confusion_matrix( y_test, y_pred_new )
[19]: array([[140,
                   9],
                 76]], dtype=int64)
            [ 18,
[20]: | accuracy_score ( y_test, y_pred_new )
[20]: 0.8888888888888888
[21]: precision_score( y_test, y_pred_new )
[21]: 0.8941176470588236
```

```
[22]: recall_score( y_test, y_pred_new )
[22]: 0.8085106382978723
[23]: f1_score(y_test, y_pred_new)
[23]: 0.8491620111731844
[24]: from sklearn.metrics import roc_curve
      fprs, tprs, thresholds = roc_curve( y_test, y_pred_proba1 )
      np.c_[ fprs, tprs, np.round( thresholds, decimals=3 ) ][:10]
[24]: array([[0.
                                                 ],
                        , 0.
             ГО.
                        , 0.0106383 , 1.
                                                 ],
                        , 0.35106383, 0.967
             [0.
                                                 ],
             [0.00671141, 0.35106383, 0.964
                                                 ],
             [0.00671141, 0.5212766 , 0.916
                                                 ],
             [0.01342282, 0.5212766 , 0.915
                                                 ],
             [0.01342282, 0.58510638, 0.891
                                                 ],
             [0.02013423, 0.58510638, 0.887
                                                 ],
             [0.02013423, 0.62765957, 0.832
                                                 ],
             [0.02684564, 0.62765957, 0.819
                                                 ]])
[25]: plt.plot( fprs, tprs, label="ROC")
      plt.plot( [0,1], [0,1],'k--', label="Random")
      plt.xlabel('FPR(1-Sensitivity)')
      plt.ylabel('TPR(Recall)')
      plt.legend()
```

[25]: <matplotlib.legend.Legend at 0x374fe42970>



```
[26]: from sklearn.metrics import roc_auc_score roc_auc_score(y_test, y_pred_proba1)
```

[26]: 0.9471655004997859